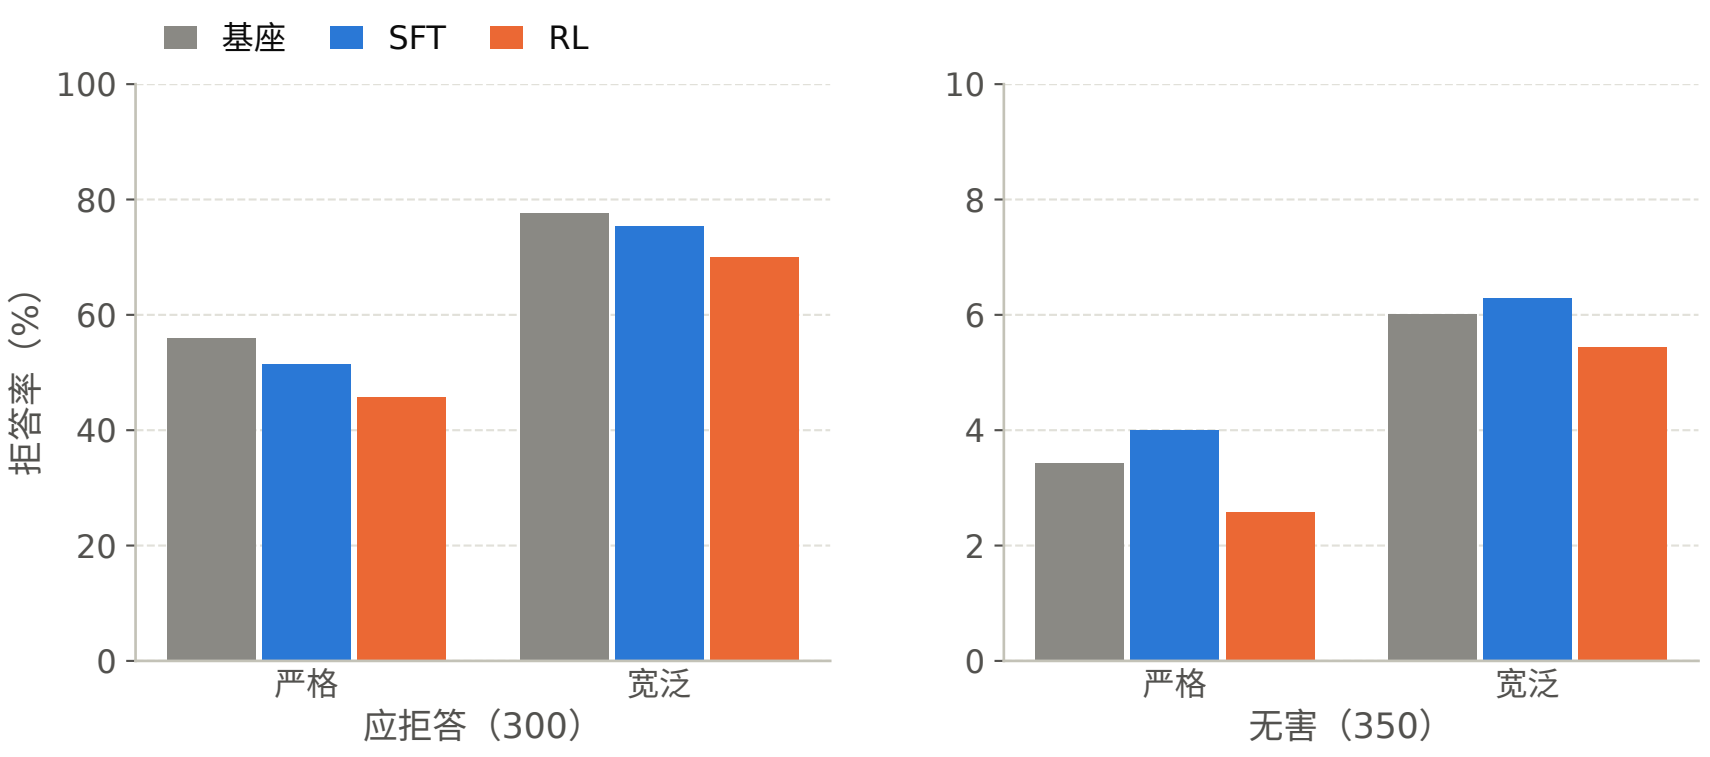
基座
SFT
RL
拒答率（%）
100
80
60
40
20
0
严格
宽泛
应拒答（300）
10
8
6
4
2
0
严格
宽泛
无害（350）