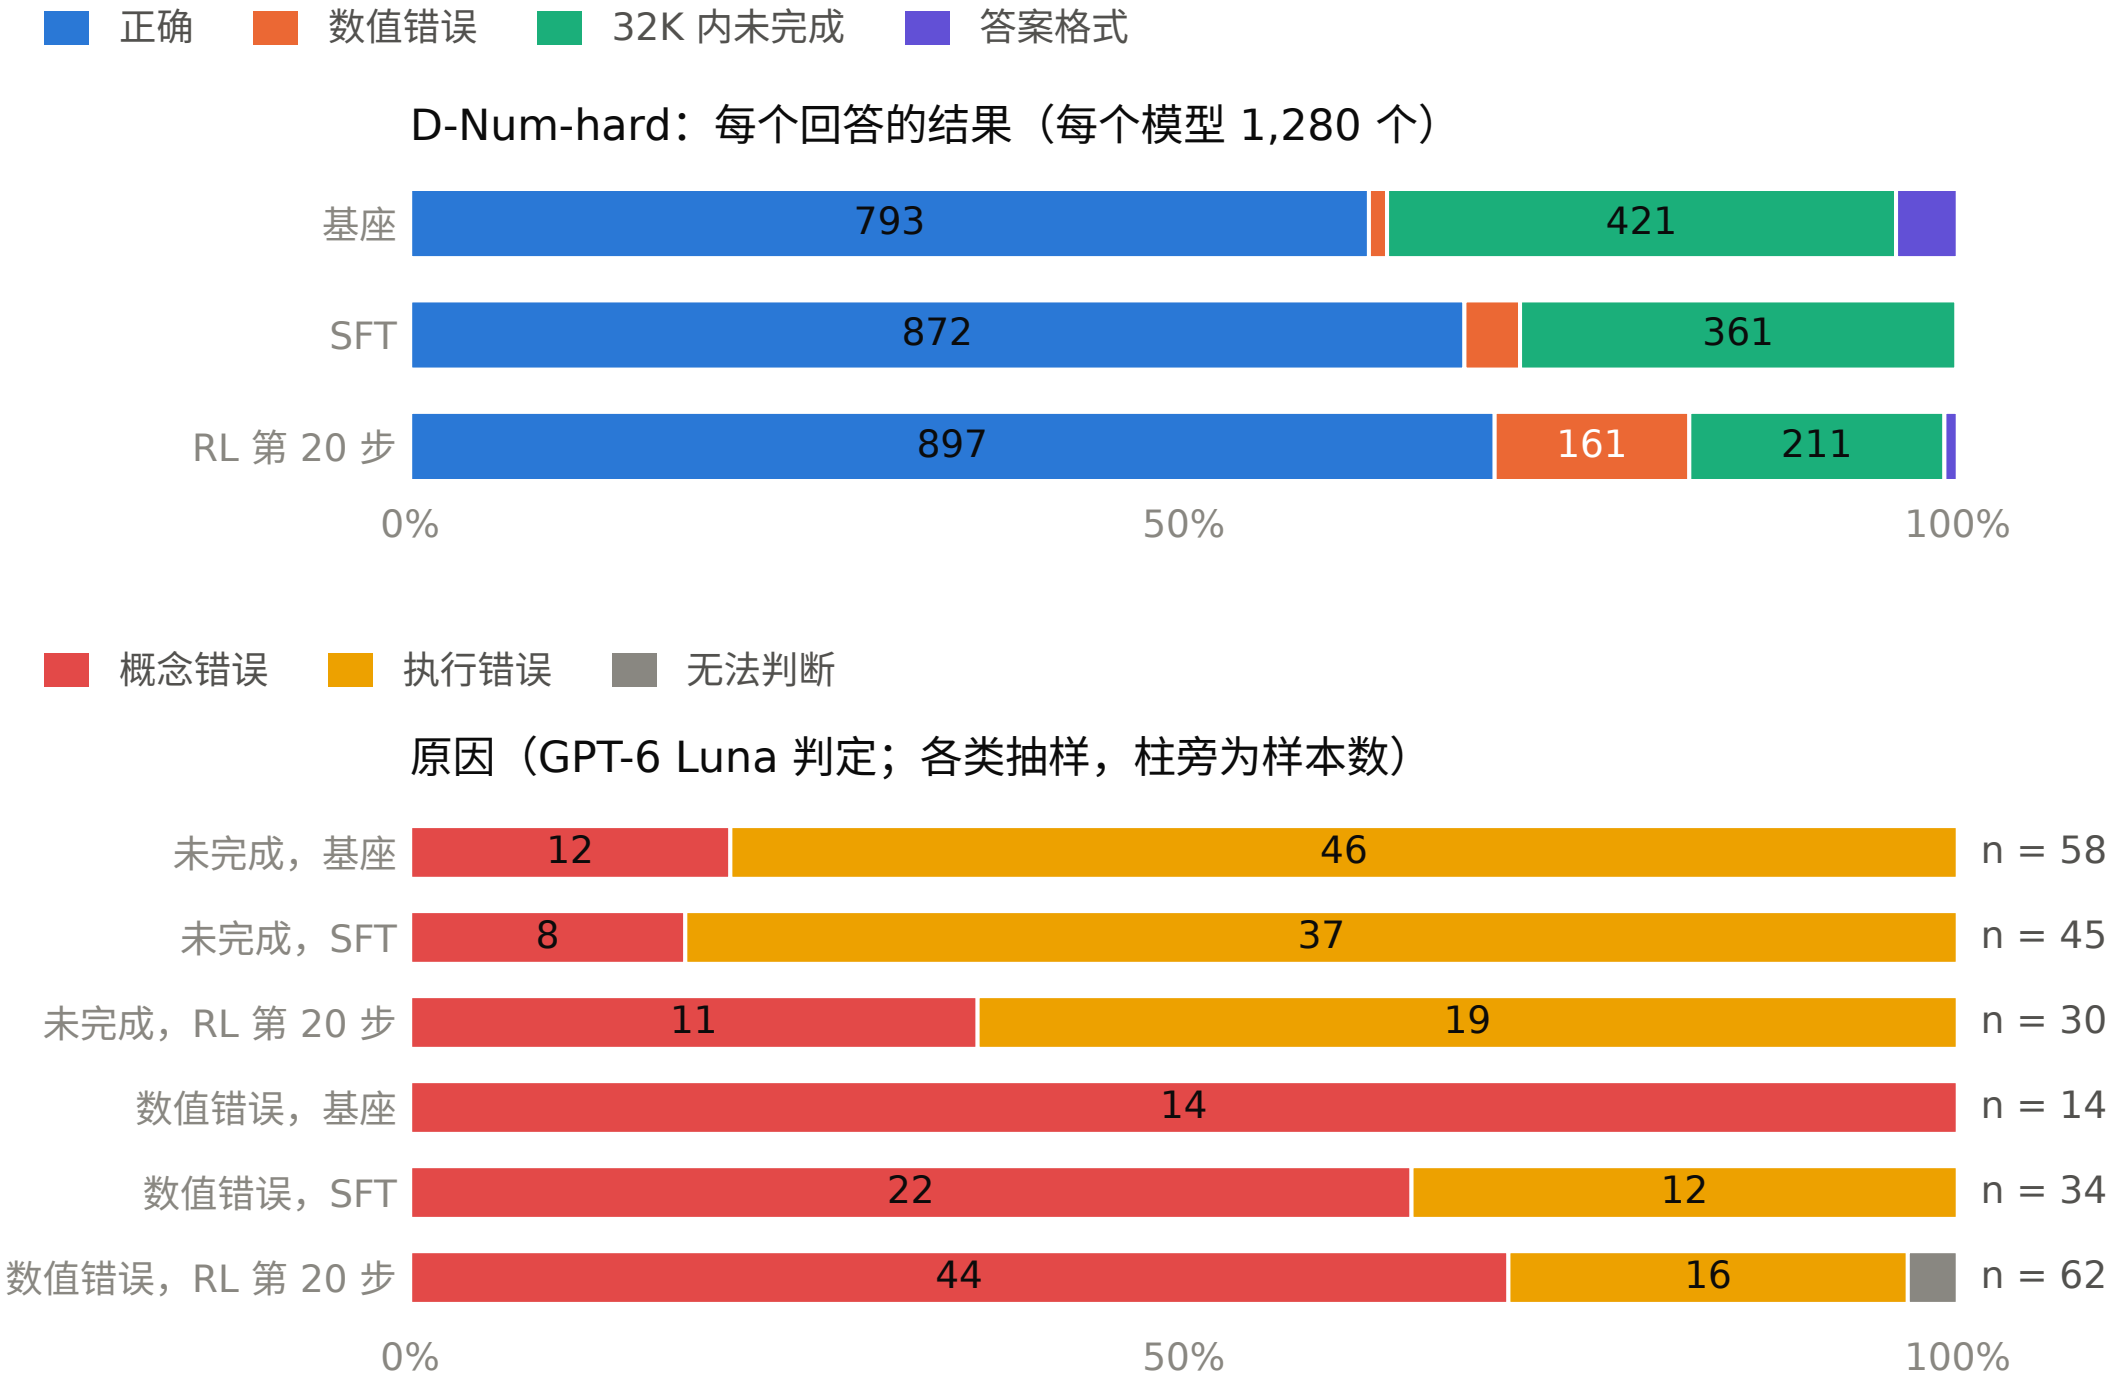
正确
数值错误
32K 内未完成
答案格式
D-Num-hard：每个回答的结果（每个模型 1,280 个）
基座
SFT
RL 第 20 步
793
421
872
361
897
161
211
0%
50%
100%
概念错误
执行错误
无法判断
原因（GPT-6 Luna 判定；各类抽样，柱旁为样本数）
未完成，基座
未完成，SFT
未完成，RL 第 20 步
数值错误，基座
数值错误，SFT
数值错误，RL 第 20 步
12
46
8
37
11
19
14
22
12
44
16
n = 58
n = 45
n = 30
n = 14
n = 34
n = 62
0%
50%
100%