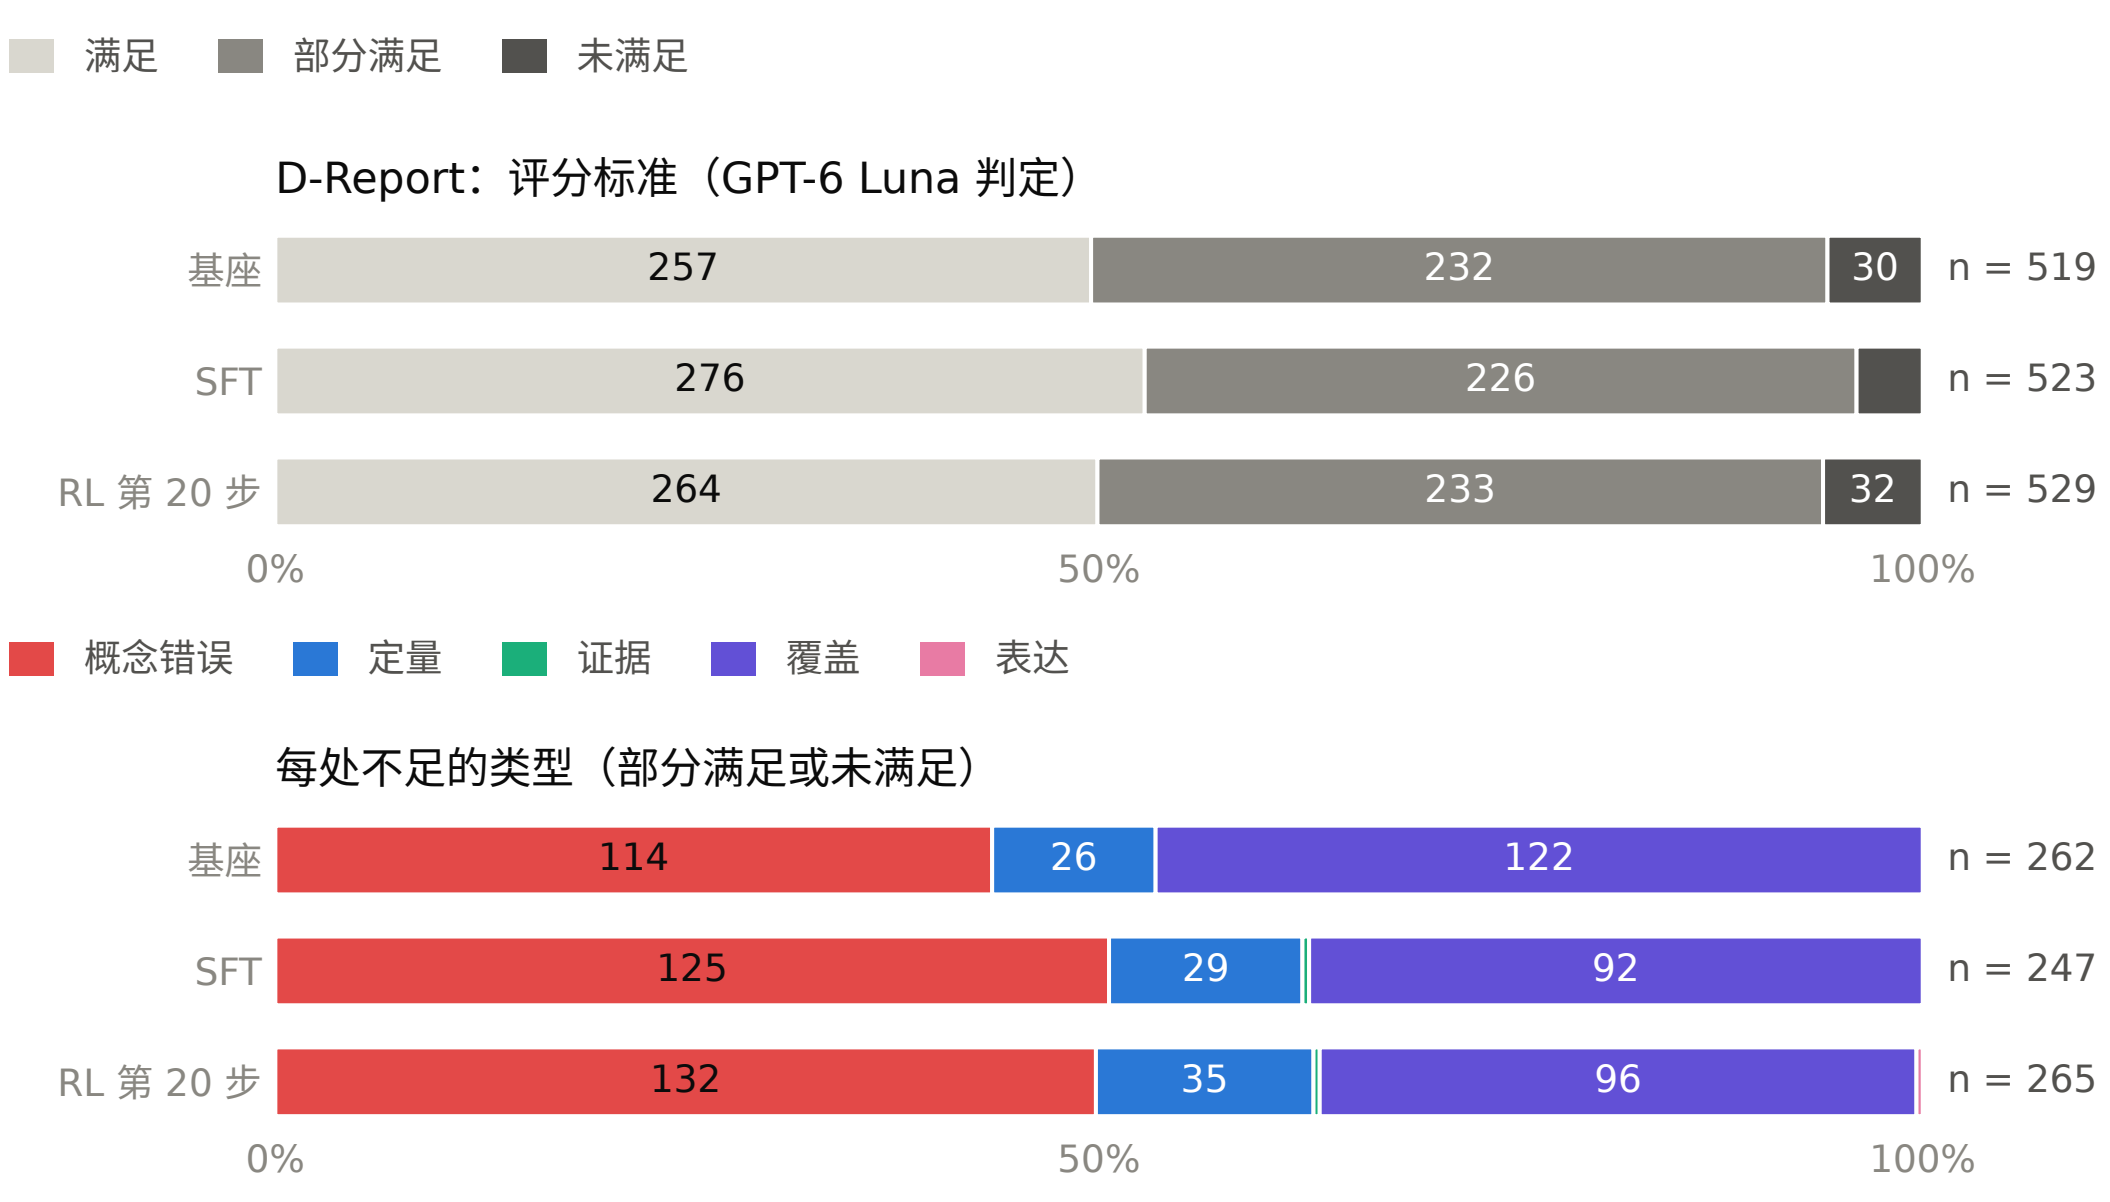
满足
部分满足
未满足
D-Report：评分标准（GPT-6 Luna 判定）
基座
257
232
30
n = 519
SFT
276
226
n = 523
RL 第 20 步
264
233
32
n = 529
0%
50%
100%
概念错误
定量
证据
覆盖
表达
每处不足的类型（部分满足或未满足）
基座
114
26
122
n = 262
SFT
125
29
92
n = 247
RL 第 20 步
132
35
96
n = 265
0%
50%
100%